

Indikatoren für einen aussagekräftigen Generative Engine Optimization (GEO) Score: Eine empirische und algorithmische Analyse

Einleitung und grundlegende Problemstellung

Mit der zunehmenden Integration von Large Language Models (LLMs) in die Architekturen globaler Suchmaschinen vollzieht sich ein fundamentaler Paradigmenwechsel im Information Retrieval. Systeme wie Google AI Overviews (ehemals Search Generative Experience), Perplexity.ai, Bing Chat und ChatGPT transformieren die herkömmliche Darstellung von Suchergebnissen grundlegend. Die etablierte Mechanik, bei der Nutzer eine Suchanfrage stellen und eine hierarchisch geordnete Liste von zehn organischen Links ("Ten Blue Links") erhalten, weicht zunehmend synthetisierten, natürlichsprachlichen Antworten, die in Echtzeit aus verschiedenen Webquellen generiert und mit sogenannten Inline-Zitationen (Citations) versehen werden.¹ Diese technologische Evolution zwingt Website-Betreiber, Digitalstrategen und Content-Ersteller dazu, grundlegend neue Optimierungsstrategien zu entwickeln, um in diesen generativen Antworten als Quelle referenziert zu werden. Dieser rasant aufstrebende Bereich wird in der akademischen und praxisbezogenen Literatur primär als Generative Engine Optimization (GEO) oder Answer Engine Optimization (AEO) bezeichnet.³

Im deutlichen Gegensatz zur traditionellen Search Engine Optimization (SEO), bei der das primäre Ziel die Maximierung der relativen Platzierung innerhalb einer statischen Suchergebnisseite ist, zielt die Generative Engine Optimization darauf ab, die Sichtbarkeit, die Zitationswahrscheinlichkeit und den semantischen Einfluss einer Informationsquelle innerhalb der dynamisch generierten Antworten von KI-Systemen zu erhöhen.³ Die Messung, Quantifizierung und Evaluierung dieser Optimierungsbemühungen stellt die aktuelle Forschung jedoch vor erhebliche methodische Herausforderungen. Generative KI-Modelle operieren als hochkomplexe, nicht-deterministische "Black-Box"-Systeme. Die Zuteilung von Sichtbarkeit erfolgt hier nicht mehr über einen transparenten Ranking-Faktor, sondern über dynamische Wahrscheinlichkeitsverteilungen bei der Textgenerierung.⁴

Der vorliegende umfassende Forschungsbericht analysiert tiefgehend und detailreich, welche Indikatoren und Metriken für die Konstruktion eines validen, aussagekräftigen "GEO-Scores" relevant sind. Die nachfolgende Analyse stützt sich hierbei auf eine breite Basis an Evidenzquellen: Sie integriert empirische Forschungsarbeiten zur Sichtbarkeit in generativen Suchmaschinen, offizielle Richtlinien von Suchmaschinenbetreibern, großangelegte Korrelationsstudien aus der Industrie aus dem Jahr 2026 sowie ein konkretes Konzept für eine Masterarbeit, welche die Unterschiede zwischen klassischen SEO-Ergebnissen und KI-Zitationen untersucht.⁶ Einen besonderen Schwerpunkt bildet die algorithmische Umsetzung

dieser theoretischen Konzepte. Hierzu wird ein in Python geschriebener GEO-Klassifikator (indicators.py und kw.ini) im Kontext der Forschungssoftware RAT (Result Assessment Tool) dekonstruiert und evaluiert.⁶ Das übergeordnete Ziel dieses Berichts ist es, eine belastbare Brücke zwischen der theoretischen Konzeptionalisierung von GEO und der algorithmischen Operationalisierbarkeit in Form messbarer Variablen zu schlagen, um so ein Fundament für einen empirisch fundierten GEO-Score zu legen.

Evolution des Information Retrieval: Der theoretische Rahmen von GEO

Um definieren zu können, was einen GEO-Score aussagekräftig macht, muss zunächst der zugrundeliegende technologische Mechanismus generativer Suchmaschinen verstanden werden. Moderne generative Suchmaschinen basieren in der Regel auf einer Retrieval-Augmented Generation (RAG) Architektur.¹⁰ In diesem architektonischen Modell generiert das Large Language Model seine Antworten nicht ausschließlich aus seinem internen, während des Trainings erworbenen parametrischen Wissen. Stattdessen greift das System in Echtzeit auf einen separaten Retrieval-Mechanismus (klassischerweise eine Suchmaschine) zu, der hochgradig relevante Dokumente aus einem umfangreichen Index abrufen.¹ Diese Dokumente werden dem LLM in seinem Kontextfenster (Context Window) als dynamisches Arbeitsgedächtnis zur Verfügung gestellt, aus dem es dann die finale, nutzerspezifische Antwort synthetisiert und die Quellen referenziert.¹

Die Kontroverse um die Sichtbarkeit: Der Princeton-Ansatz versus die Martinez-Kritik

Die akademische Debatte um die Mechanismen von GEO wird maßgeblich von zwei unterschiedlichen Forschungsperspektiven geprägt, die direkte und weitreichende Auswirkungen auf die Konstruktion eines GEO-Scores haben. Die Berücksichtigung beider Perspektiven ist für die Entwicklung einer validen Metrik essenziell.

Die grundlegende, feldbegründende Studie der Princeton University (Aggarwal et al., 2024) prägte den Begriff GEO und demonstrierte in kontrollierten, simulatorbasierten Experimenten, dass gezielte inhaltliche Modifikationen an Webtexten die Sichtbarkeit einer Quelle in LLM-Antworten um bis zu 40 Prozent steigern können.¹ Die Forscher identifizierten spezifische Optimierungsstrategien, die zu signifikanten Sichtbarkeitsgewinnen führten. Zu diesen Erfolgsfaktoren gehörten das Hinzufügen von quantitativen Statistiken, das Einfügen von direkten Zitaten, die Etablierung eines autoritären Schreibstils sowie eine gezielt optimierte, vereinfachte Lesbarkeit.¹³ Diese Faktoren bilden bis heute das theoretische Rückgrat vieler aktueller GEO-Optimierungsansätze und Software-Tools.

Eine umfassende kritische Evaluation dieser initialen Erkenntnisse durch Martinez (2026) in einem systematischen arXiv-Survey relativiert diese Ergebnisse jedoch und bietet ein wesentlich differenzierteres, praxisnäheres Framework.⁴ Der Survey argumentiert überzeugend, dass die in der Industrie weit verbreitete Behauptung einer generellen "40-prozentigen Sichtbarkeitssteigerung" isoliert betrachtet irreführend ist. Diese Zahl basiere

auf einem sehr spezifischen Metrik-Design (dem "Position-Adjusted Word Count"), das voraussetzt, dass das zu bewertende Dokument dem LLM bereits erfolgreich im Kontextfenster zur Verfügung gestellt wurde.⁵ Martinez postuliert stattdessen, dass GEO keine singuläre, eindimensionale Ranking-Aufgabe ist, sondern eine probabilistische, partiell beobachtbare Pipeline, die aus mehreren sequenziellen Stufen besteht, an denen ein Dokument scheitern kann.⁴

Diese mehrstufige Pipeline umfasst folgende Phasen, die ein aussagekräftiger GEO-Score allesamt berücksichtigen muss⁴:

1. **Search Activation:** Die initiale Entscheidung des generativen Systems, ob für eine spezifische Anfrage überhaupt externe Quellen aus dem Web abgerufen werden müssen, oder ob parametrisches Wissen ausreicht.
2. **Crawling and Indexing:** Die grundlegende Voraussetzung, ob das Quelldokument von den Crawlern des Systems erfasst und im Basis-Index der Suchmaschine fehlerfrei vorgehalten wird.
3. **Retrieval:** Die klassische Phase, in der entschieden wird, ob das Dokument für den spezifischen (häufig durch die KI im Hintergrund umformulierten) Prompt aus dem Index abgerufen wird.
4. **Reranking and Context Allocation:** Die hochgradig kompetitive Phase, in der festgelegt wird, ob das abgerufene Dokument einen der stark limitierten Plätze im begrenzten Kontextfenster des LLMs erhält.
5. **Citation and Prominence:** Die eigentliche generative Phase, in der das LLM entscheidet, ob es überhaupt Informationen aus diesem spezifischen, im Kontextfenster liegenden Dokument extrahiert und es als sichtbares Inline-Zitat ausweist.
6. **Factual Absorption:** Die inhaltliche Phase, in der bestimmt wird, ob das LLM die Fakten aus der Quelle unverfälscht übernimmt, oder ob es Informationen aus anderen Quellen synthetisiert und potenziell verfälscht (Halluzination).

Ein aussagekräftiger GEO-Score muss folglich Variablen beinhalten, die alle kritischen Phasen dieser RAG-Pipeline abdecken. Ein isolierter Score, der lediglich den Schreibstil oder die rhetorische Qualität (Citation and Prominence) bewertet, ohne die technische Crawlbarkeit (Crawling) zu prüfen, ist methodisch ebenso wertlos wie ein rein klassischer technischer SEO-Score, der die linguistische Extrahierbarkeit für das LLM ignoriert.

Die Divergenz von klassischem SEO und GEO in der Praxis

Google selbst vertritt in offiziellen Richtlinien (insbesondere dem im Mai 2026 veröffentlichten Dokument "Optimizing your website for generative AI features on Google Search") die konservative Position, dass die Optimierung für generative KI-Suchen im Kern immer noch klassische SEO sei.³ Der Suchmaschinenbetreiber rät explizit von isolierten, neuartigen Optimierungs-Hacks ab – wie etwa der Erstellung spezieller lms.txt-Dateien oder künstlich erzwungenem Content-Chunking. Das Unternehmen betont stattdessen, dass die generativen Features in Googles bestehenden Kern-Ranking- und Qualitätssystemen verwurzelt sind.¹¹ Aus dieser technischen Perspektive heraus müssen Seiten nach wie vor discoverable (auffindbar), crawlable (durchsuchbar) und indexierbar sein, um überhaupt für eine KI-Übersicht infrage zu

kommen.¹¹

Trotz dieser offiziellen Kommunikation widerlegen großangelegte empirische Analysen führender Datenanbieter aus dem Jahr 2026 die vereinfachte Annahme, dass klassische Top-10-Rankings in der organischen Suche automatisch oder zwangsläufig zu KI-Zitationen führen. Die Daten zeigen vielmehr eine drastische Entkopplung der beiden Systeme auf. Eine tiefgehende Analyse von Moz, die 40.000 spezifische Suchanfragen im Google AI Mode evaluierte, ergab, dass bemerkenswerte 88 Prozent der KI-Zitationen aus Quellen stammten, die sich nicht in den organischen Top-10-Ergebnissen der klassischen Suche befanden.⁷

Ähnliche Studien von BrightEdge und anderen Analyseplattformen bestätigen diesen Trend und zeigen, dass in Google AI Overviews lediglich etwa 38 Prozent der zitierten URLs auch parallel in den Top 10 ranken – ein Wert, der von zuvor rund 76 Prozent im Vorjahr massiv gesunken ist.⁸ Diese massive statistische Diskrepanz belegt eindrucksvoll, dass LLM-basierte Suchmaschinen nach einer grundlegend anderen Informationsabruf- und Zitationslogik arbeiten als der klassische PageRank-Algorithmus.⁷ Traditionelle Ranking-Faktoren wie die übergeordnete Domain Authority oder reine, massenhaft aufgebaute Backlink-Profile korrelieren in den neuesten Datenreihen deutlich schwächer mit KI-Zitationen als Faktoren wie Markenerwähnungen in der Breite des Webs, inhaltliche Frische der Dokumente und vor allem die strukturelle Klarheit der bereitgestellten Daten.² Ein valider GEO-Score darf daher traditionelle SEO-Scores nicht einfach übernehmen oder leicht modifizieren, sondern muss eine profunde Neugewichtung der Indikatoren vornehmen, die sich an der algorithmischen Realität von RAG-Pipelines orientiert.

Konzeptionelle Grundlagen: Das Forschungsdesign und die RAT-Software

Die Konzeption eines Masterarbeitsprojekts zur systematischen, empirischen Untersuchung von SEO- versus GEO-Mustern mittels der Forschungssoftware RAT (Result Assessment Tool) liefert einen hervorragenden und strukturierten Ausgangspunkt für die Definition relevanter Variablen und Indikatoren.⁶ Die dazugehörige algorithmische Implementierung im Python-Klassifikator (indicators.py) zeigt auf höchst detaillierte Weise auf, wie diese theoretischen Konzepte technologisch erhoben, gemessen und in einen maschinellen Bewertungsprozess überführt werden können.⁶

Das Forschungsdesign der Masterarbeit definiert eine "Query Sampler Study", bei der ein vielfältiges Set an Suchanfragen genutzt wird, um zwei klar getrennte Gruppen zu untersuchen: Gruppe A besteht aus den Quellen, die in Google AI Overviews zitiert werden, während Gruppe B die klassischen Top 10 der organischen Suchergebnisse abbildet.⁶ Diese methodische Trennung ist entscheidend, um exakt jene Variablen zu isolieren, die überproportional häufig bei KI-Zitationen (Gruppe A) auftreten und somit als verlässliche Indikatoren für einen GEO-Score fungieren.

Die Herausforderung bei der Untersuchung von Suchmaschinen-Bias und der Identifikation von Ranking-Faktoren liegt traditionell in der fehlenden Datenzugänglichkeit und dem Black-Box-Charakter der Algorithmen.²² Die eingesetzte Forschungssoftware RAT, die

kontinuierlich von der Forschungsgruppe um Dirk Lewandowski (HAW Hamburg) entwickelt wird, adressiert dieses epistemologische Problem direkt. Sie bietet eine integrierte, automatisierte Umgebung für das Design von Studien, die massenhafte automatisierte Datensammlung und die anschließende computergestützte Analyse.⁹

Der analysierte Python-Code (indicators.py) repräsentiert einen funktionalen Kernbestandteil des RAT Backend und verdeutlicht die Mächtigkeit und technische Tiefe dieses Ansatzes für GEO-Studien⁶: Anstatt manuelle Inspektionen durchzuführen, simuliert das Skript über einen SeleniumBase-Driver einen echten, menschlichen Nutzer. Durch Konfigurationen wie undetectable=True, headless2=True und das Setzen spezifischer User-Agent-Strings maskiert sich der Crawler effektiv gegen Anti-Bot-Mechanismen, um unverfälschte Ergebnisse im realen Zustand (inklusive dynamischer JavaScript-Inhalte) abzurufen.⁶ Diese Form der Datenextraktion ist essenziell, da viele LLM-basierte Suchmaschinen hochgradig personalisierte oder dynamisch generierte Overviews ausspielen, die durch einfache HTTP-Requests oft nicht erfassbar sind.

Basierend auf der Synthese aus empirischer Literatur, der detaillierten Variablen-Konzeption der RAT-Studie⁶ und der Logik des Python-Klassifikators⁶ lassen sich die relevanten Indikatoren für einen belastbaren GEO-Score in fünf zentrale, nach Relevanz gewichtete Dimensionen unterteilen.

Dimension 1: Technische Erreichbarkeit und Crawling-Fundamente

Bevor ein Large Language Model einen Text überhaupt verarbeiten, synthetisieren oder zitieren kann, muss der vorgelagerte Crawler das Dokument erfassen und der Retrieval-Algorithmus der Suchmaschine es indizieren können.²⁴ Technische Barrieren wirken in der RAG-Pipeline als absolute Ausschlusskriterien ("Gatekeeper"). Ein Dokument, das nicht im Index liegt, existiert für das Sprachmodell faktisch nicht, unabhängig von seiner linguistischen Brillanz oder faktischen Tiefe. In einer umfassenden Meta-Analyse von Zyppey aus dem Jahr 2026 wurde die "URL Accessibility" mit 9.5 von 10 möglichen Punkten als der absolut stärkste, unverhandelbare Faktor für KI-Zitationen identifiziert.⁸ Eine Seite, die blockiert, durch Paywalls geschützt ist oder HTTP-Fehler zurückgibt, kann per Definition nicht zitiert werden.⁸

Der Python-Klassifikator operationalisiert diese kritische technische Dimension durch mehrere präzise Metriken, die das Fundament eines jeden GEO-Scores bilden müssen⁶:

- **Ladezeitenmessung (calculate_loading_time):** Die Messung der Seitenladezeit ist nicht nur ein UX-Faktor, sondern operativ kritisch. Autonome KI-Crawler (wie Google-Extended, der GPTBot von OpenAI oder der ClaudeBot von Anthropic) operieren mit extrem engen Timeouts, um enorme Datenmengen effizient verarbeiten zu können, was oft als Crawl-Budget bezeichnet wird.²⁴ Bei langsamen Seiten bricht der Crawler die Verbindung ab, bevor der HTML-Body mit dem relevanten Text vollständig übertragen wurde.²⁵ Das RAT-Skript misst diese Ladezeit nicht über einfache Ping-Anfragen, sondern greift direkt auf window.performance.timing via JavaScript-Execution im simulierten Browser zurück, um die reale Dauer bis zum navigationStart bis zum Abschluss des

Renderings präzise zu erfassen.⁶ Überschreitet dieser Wert einen definierten Threshold, muss der GEO-Score empfindlich herabgestuft werden.

- **Indexierungs-Direktiven (save_robot_txt und identify_robots_txt):** LLM-Systeme respektieren weitgehend die Anweisungen in der Servereinstellungsdatei robots.txt.²⁵ Die automatisierte Überprüfung auf Direktiven, die spezifische KI-Bots ausschließen (z. B. ein Verbot für den GPTBot) oder ein generelles noindex vorgeben, ist ein zwingender Bestandteil.⁶ Das RAT-Skript ruft diese Datei explizit ab und durchsucht sie nach Schlüsselwörtern wie crawl-delay, user-agent oder noindex. Ein Konfigurationsfehler an dieser Stelle senkt den effektiven GEO-Score auf null, da die erste Stufe der von Martinez beschriebenen Pipeline (Crawling) scheitert.⁶
- **Rendering-Komplexität und JavaScript:** Viele dedizierte LLM-Crawler verarbeiten JavaScript im Gegensatz zum hochkomplexen Googlebot nur rudimentär.²⁵ Wenn relevante Inhalte (z.B. Produktbeschreibungen oder Fachartikel) erst nachträglich im Browser des Nutzers über JavaScript asynchron nachgeladen werden (Client-Side Rendering), bleiben diese Informationsblöcke für einfachere KI-Crawler oft gänzlich unsichtbar.¹¹ Ein GEO-Score muss die Präsenz von sauberem, statischem HTML (Server-Side Rendering) positiv bewerten.
- **Trust- und Konfliktsignale:** Metriken wie identify_https(url) zur Sicherstellung einer verschlüsselten Verbindung als grundlegendes Trust-Signal⁶, identify_viewport(source) für die Bestätigung der mobilen Reaktionsfähigkeit und identify_canonical(source) zur Vermeidung von Entity-Konflikten durch Duplicate Content runden die technische Basisbewertung ab.⁶ Wenn Duplicate Content vorliegt, fragmentieren sich die Konsenssignale einer Entität, was die Wahrscheinlichkeit einer KI-Zitation drastisch senkt.

Dimension 2: Semantische Datenstrukturierung und Entitäts-Klarheit

Während menschliche Leser visuelle Layouts nutzen, um Wichtiges von Unwichtigem zu trennen, verarbeiten LLMs Text als reine Vektor-Repräsentationen. Zwar sind moderne Sprachmodelle exzellent darin, unstrukturierten Text zu begreifen, jedoch sind sie für die hochpräzise, halluzinationsfreie Faktenextraktion ("Factual Absorption") stark auf eindeutige semantische Signale im Quellcode angewiesen.⁴ Je klarer Entitäten (wie Personen, Unternehmen, Produkte oder theoretische Konzepte) maschinenlesbar deklariert und logisch voneinander abgegrenzt sind, desto seltener entstehen Mehrdeutigkeiten (Entity Ambiguity). Eine geringe Mehrdeutigkeit resultiert direkt in einem signifikant höheren Vertrauen der Retrieval-Engine in die Informationsquelle.¹⁰

Die Analyse der konzeptionellen RAT-Variablen und des Python-Klassifikators zeigt in dieser Dimension eine extrem starke Fokussierung auf semantisches Markup und maschinenlesbare Formatierung.⁶

JSON-LD, Microdata und die Entitätsauflösung

Die Funktion analyze_microdata_advanced im Python-Skript ist ein zentraler

Bewertungsmechanismus für den GEO-Score.⁶ Der Klassifikator vergibt explizit hohe Punktwerte (jeweils bis zu 50 Punkte) für die Präsenz von JSON-LD-Skriptblöcken (`<script type="application/ld+json">`) sowie für klassische, in HTML eingebettete Microdata-Attribute (`itemscope`, `itemtype`, `itemprop`).⁶ Diese strukturierten Daten nach dem Schema.org-Standard dienen als direkte, unmissverständliche Übersetzungshilfe für komplexe RAG-Pipelines. Wenn eine Webseite beispielsweise ein Unternehmen, ein Produkt oder einen Fachartikel durch strukturiertes Markup semantisch auszeichnet, entfällt für das Sprachmodell die Notwendigkeit, diese Parameter aufwendig und fehleranfällig aus dem Fließtext zu inferieren. Das Modell kann Fakten wie Preise, Adressen, Autorenschaften oder Veröffentlichungsdaten mit maximaler Konfidenz extrahieren und in seine generative Antwort einbetten.⁷ Das Konzept der RAT-Masterarbeit sieht zudem vor, gezielt Unternehmenssignale zu erfassen (`analyze_company_signals`). Dabei durchsucht der Classifier Schema-Definitionen nach Begriffen wie "organization" oder "publisher" und analysiert den Footer-Bereich nach rechtlichen Pflichtseiten wie "Impressum" oder "Über uns".⁶ Dies fungiert als hochwirksamer Proxy für rechtliche Transparenz und eindeutige Entitätszuordnung, was unmittelbar auf das E-E-A-T-Konzept (Experience, Expertise, Authoritativeness, Trustworthiness) der Suchmaschinen einzahlt.²

HTML-Hierarchien und tabellarische Datenstrukturen

Empirische Analysen von Dezember 2025 belegen, dass LLM-basierte Suchmaschinen Dokumente mit einem "strukturiertem, hierarchischem HTML" statistisch hochsignifikant bevorzugen.⁷ Der Python-Klassifikator trägt diesem Umstand durch die Funktion `identify_structure_elements` Rechnung.⁶ Hierbei wird das DOM nach semantischen Gruppierungselementen wie Tabellen (`<table>`), ungeordneten und geordneten Listen (`<ul>`, `<ol>`) sowie den zugehörigen Listenelementen (`<li>`) durchsucht.⁶

Eine logische, tiefgehende Strukturierung (beispielsweise eine konsistente Abfolge von H2-Überschriften, gefolgt von H3-Unterpunkten und abschließenden Aufzählungslisten) erhöht laut Branchenstudien die Wahrscheinlichkeit einer KI-Zitation um signifikante 40 Prozent.²⁰ Tabellen stellen in diesem Kontext einen besonders wertvollen Informations-Asset dar. Sie liefern verdichtete, komparative Daten, die Sprachmodelle über ihre Aufmerksamkeitsmechanismen weitaus leichter und fehlerfreier miteinander in Bezug setzen können als in langatmigen Fließtexten verborgene Vergleiche.⁷ Ein aussagekräftiger GEO-Score muss die Informationsdichte in Form dieser strukturierten Elemente quantifizieren und positiv in die Endbewertung einfließen lassen. In der Meta-Analyse von Zyppe wird die "Structure" (die Extrahierbarkeit von Passagen) mit einem Score von 8.6 von 10 als einer der Top-Faktoren gewichtet.⁸

Dimension 3: Linguistische Extraktionsfähigkeit, Lesbarkeit und Tonalität

Eine der markantesten und analytisch faszinierendsten Abweichungen zwischen klassischem SEO und moderner GEO liegt in der fundamental geänderten Bedeutung der linguistischen

Komplexität.²⁷ In der menschlichen, oft akademisch geprägten Wahrnehmung gelten lange, verschachtelte und mit Fachtermini durchsetzte Texte (auf Postgraduate-Level) traditionell als Indikator für tiefes Expertenwissen. Für die Attention-Layer (Aufmerksamkeitsmechanismen) von modernen Transformermodellen stellt eine derart hohe diskursive Dichte bei der zielgerichteten Beantwortung spezifischer Nutzer-Queries jedoch ein massives informationelles Rauschen dar. Generative Engines präferieren stark solche Quellen, die sie recheneffizient parsen, schnell interpretieren und ohne großes Halluzinations-Risiko in Form kurzer Snippets wörtlich zitieren können.²⁷

Der RAT-Python-Klassifikator setzt diese komplexe linguistische Erkenntnis durch fortschrittliche Textanalyse-Algorithmen um, die für die Berechnung eines GEO-Scores unerlässlich sind.⁶

Readability-Scores und Flesch-Kincaid-Grenzwerte

Ein zentraler Bestandteil des Klassifikators ist die Funktion `analyze_readability`. Hierbei wird, nachdem störende Elemente wie Navigation, Footer und Styling-Tags aus dem DOM-Baum entfernt wurden, die `textstat`-Bibliothek aufgerufen, welche im vorliegenden Fall auf die deutsche Sprache kalibriert ist.⁶ Ermittelt wird primär der "Flesch Reading Ease" Score. Die angewandte Forschung von Agenturen wie Rocketblue (vormals Spotlight) zeigt eindeutig, dass LLMs Texte auf einem Flesch-Niveau zwischen 60 und 75 bevorzugen.²⁷ In den USA entspricht dies einem Schulniveau der Klassen 6 bis 8; im Deutschen einer gut verständlichen, klaren Sprache ohne exzessive Schachtelsätze.

In diesem spezifischen Lesbarkeits-Band sind die Sätze kurz und kompakt genug, um ohne kontextuellen Bedeutungsverlust als präzises Zitat extrahiert zu werden, klingen aber dennoch professionell und autoritär.²⁷ Texte, die in den Flesch-Bereich unter 40 abrutschen (akademisch, hochkomplex), werden von Generativen Engines seltener zitiert, da das Risiko steigt, dass das Modell bei der komprimierenden Zusammenfassung semantische Nuancen zerstört. Ein GEO-Score muss folglich die Lesbarkeit nicht nach dem Prinzip "je höher, desto besser" (oder umgekehrt) bewerten, sondern eine glockenförmige Verteilung anlegen, bei der Werte im mittleren, klaren Spektrum (60-75) die höchste Punktzahl erhalten.

Absatzarchitektur und Question-Answer-Formate (FAQs)

Parallel zur Satzebene untersucht die Funktion `analyze_paragraphs` die Makrostruktur des Textes.⁶ Durch das Zählen der Absatz-Elemente (`<p>`) und die Berechnung der durchschnittlichen Wort- und Satzanzahl pro Absatz wird ein Indikator für die visuelle und maschinelle "Scannability" erstellt.⁶ LLM-Zusammenfassungen greifen bevorzugt auf isolierte, in sich geschlossene Fakten in kurzen Absätzen zurück. Empirische Tests empfehlen hier eine Dichte von 15 bis 18 Wörtern pro Satz und eine Begrenzung auf maximal drei Sätze pro Absatz.²⁷

Darüber hinaus identifiziert die Funktion `identify_faqs_advanced` gezielt semantische Frage-Antwort-Muster.⁶ Das Skript sucht dabei nicht nur nach explizitem FAQPage-Schema, sondern analysiert den Text semantisch: Es sucht nach Überschriften (H2 bis H4), die mit einem Fragezeichen enden, gefolgt von einem Textblock, der eine gewisse Mindestlänge (mehr als 5

Wörter) aufweist.⁶ Dieser Ansatz ist von enormer Tragweite: LLMs sind durch Instruction Fine-Tuning fundamental darauf trainiert, direkte Antworten auf gestellte Fragen zu geben. Web-Inhalte, die bereits im "Answer-First"-Format verfasst sind und als direkte, deklarative Antwort auf eine potenziell vom Nutzer gestellte Frage vorliegen, spiegeln die latente mathematische Struktur des Modells perfekt wider. Sie werden mit einer massiv höheren Wahrscheinlichkeit unmodifiziert in die finale KI-Antwort überführt.⁷

Ergänzt wird dies durch die in der Princeton-Studie nachgewiesene Relevanz eines "autoritären Stils". Die Taktik "Authoritative Tone" erhöhte dort die Zitationsrate um durchschnittlich 25 Prozent.¹⁰ Unsicherheiten in der Sprache, manifestiert durch Konjunktive oder Relativierungen ("könnte", "vielleicht", "es scheint"), signalisieren dem Wahrscheinlichkeitsmodell der KI eine geringe Fakten-Konfidenz.¹⁰ Obwohl eine rein auf Heuristiken basierende algorithmische Analyse diesen Tonfall nur schwer in Gänze exakt messen kann, dienen die klaren Q&A-Strukturen und eine optimierte Lesbarkeit im Klassifikator als starke, verlässliche Proxy-Variablen für diese formale Klarheit und Bestimmtheit.⁶

Dimension 4: Autoritätssignale, Evidenz und Zitationsnetzwerke

Die wohl stärksten und verlässlichsten Hebel zur direkten Manipulation der GEO-Sichtbarkeit, die von Aggarwal et al. (Princeton) in großangelegten Simulationen identifiziert wurden, betreffen das direkte Einfügen von unwiderlegbaren Beweisen ("Evidence") in den Webtext.¹ Wenn ein RAG-System in der Phase der Context Allocation entscheiden muss, welche der aus dem Index abgerufenen Quellen es für die endgültige Antwort priorisiert und zitiert, gewinnen fast immer jene Dokumente, die objektive, nachprüfbare und extrahierbare Datenpunkte liefern.⁵ Generative Engines fungieren hier als hochgradig risikoaverse Editoren.

Das RAT-Klassifikator-Skript verfügt über dedizierte, hochspezialisierte Funktionen, um exakt diese GEO-Trigger algorithmisch zu erfassen und für ein Scoring-Modell nutzbar zu machen.⁶

Statistische Dichte und Named Entity Recognition (NER)

Die Princeton-Studie zeigte einen drastischen Sichtbarkeits-Boost von 37 Prozent auf, wenn vage qualitative Aussagen in Webtexten durch harte Zahlen (Statistiken) ersetzt wurden.¹⁰ KI-Modelle extrahieren und reproduzieren konkrete Datenpunkte wesentlich verlässlicher als deskriptive, narrative Behauptungen.¹⁰ Der Classifier operationalisiert diese Erkenntnis durch die Funktion `identify_statistics_and_entities_universal`.⁶ Das Skript nutzt zum einen schnelle reguläre Ausdrücke (Regex), um das Vorkommen von Prozentzeichen (%) und historischen Formaten wie Jahreszahlen (19XX, 20XX) zu quantifizieren.⁶ Zum anderen bedient es sich fortgeschrittener Methoden des Natural Language Processing (NLP): Mithilfe der Bibliothek `spacy` wird eine Named Entity Recognition (NER) über die ersten 100.000 Zeichen des Textes durchgeführt, um explizit die Häufigkeit von Organisationen (ORG Tags) zu zählen.⁶ Das massierte Vorhandensein von benannten, real existierenden Organisationen gepaart mit Jahreszahlen und Prozentwerten ist für den Algorithmus ein extrem starker, unwiderlegbarer Indikator für hochgradig informationsdichten, zitierfähigen und somit wertvollen Content.¹⁰

Die folgende Tabelle fasst die empirisch gemessenen Sichtbarkeits-Boosts der Princeton-Studien mit der korrespondierenden Messmethodik in der RAT-Software zusammen, um die Relevanz für den GEO-Score zu verdeutlichen:

GEO-Strategie (Aggarwal et al.)	RAT/Python-Operationalisierung (Classifier)	Gemessener relativer Sichtbarkeits-Boost
Cite Authoritative Sources	get_hyperlinks (Zählen externer Domains), spacy NER (ORG Tags)	+ 40 % ¹⁰
Statistics Addition	identify_statistics_and_entities_universal (Regex für %, Jahreszahlen)	+ 37 % ¹⁰
Quotation Addition	identify_authority_signals (Zählen von <blockquote>, rel="author")	+ 30 % ¹⁰
Authoritative Tone	analyze_readability (Flesch), Q&A Strukturen (identify_faqs_advanced)	+ 25 % ¹⁰

Primärquellen, Expertenzitate und E-E-A-T-Signale

Neben reinen Datenpunkten erzeugen auch direkte Zitate von Experten eine erhebliche Hebelwirkung. Die Taktik "Quotation Addition" erhöhte in der besagten Studie die Sichtbarkeit teils um 30 bis über 40 Prozent.¹⁰ Das Python-Skript prüft HTML-Dokumente über die Funktion `identify_authority_signals` systematisch auf <blockquote>-Tags sowie semantische Autor-Attribute wie `rel="author"` oder `name="author"`.⁶ Ein direktes Zitat eines namentlich genannten und mit Titeln versehenen Experten signalisiert dem LLM eine vorab durch den Autor verifizierte Beweiskette. Das RAG-System behandelt diese Passagen als "pre-vetted evidence" und übernimmt sie weitaus bereitwilliger in die Antwortausgabe.¹⁰ Ebenso entscheidend ist die Verlinkungsstruktur nach außen. Das Extrahieren und Zählen von Verlinkungen auf primäre Quellen (externe ausgehende Links, ermittelt durch die Funktion `get_hyperlinks`) steigert die formale Glaubwürdigkeit der eigenen Behauptungen innerhalb des maschinellen Bewertungsprozesses.⁶ Ein Artikel, der auf Regierungsdaten, wissenschaftliche Peer-Review-Paper oder originäre Studien verlinkt, baut eine Kette des Vertrauens auf, die vom LLM bei der Quellenauswahl hochgradig belohnt wird.

Dimension 5: Relevanz-Metriken und der

Paradigmenwechsel im Off-Page-Bereich

Trotz der massiven Verlagerung hin zu semantischem Verständnis und KI-Generierung bleiben klassische Keyword- und Off-Page-Metriken relevant – allerdings in einer stark veränderten, oft kontraintuitiven Form. Sie sind nicht mehr entscheidend für die Textgenerierung an sich, wo plumpes "Keyword Stuffing" von Generativen Engines sogar aktiv bestraft wird und die Sichtbarkeit empirisch um etwa 10 Prozent senkt.¹⁰ Vielmehr sind sie der entscheidende Treibstoff für die initiale *Retrieval*-Phase (Phase 3 in Martinez' Modell).¹⁵ Das LLM kann ein Dokument nur dann evaluieren und zitieren, wenn die zugrundeliegende Suchmaschine es dem Kontextfenster überhaupt zuführt.⁴

Die intelligente Integration der RAT-Software mit einer externen Konfigurationsdatei (kw.ini) zeigt, wie feingranular diese Relevanz gemessen werden muss.⁶

Keyword-Metriken und semantisches Rauschen

Die Funktion `identify_keywords_in_source` verwendet differenzierte XPath-Ausdrücke aus der `kw.ini`, um nicht nur zu zählen, wie oft ein Begriff vorkommt, sondern präzise zu prüfen, in welchem strukturellen Kontext die Suchbegriffe platziert sind.⁶ Das Skript unterscheidet strikt zwischen der Platzierung im `<title>`, in Standard-Metadaten (`meta[@name='description']`), in Social-Media-spezifischen Open-Graph-Tags (`og:title`, `og:description`) und dem sichtbaren Body-Text (`//body//*[text()]`) sowie in Ankertexten von Links (`//a/text()`).⁶

Interessanterweise dient die Berechnung der klassischen Keyword-Dichte (`identify_keyword_density`) in einem modernen GEO-Kontext weniger der Belohnung hoher Werte. Da RAG-Systeme semantische Konzepte über Vektor-Embeddings abbilden und verstehen, tritt die starre Keyword-Wiederholung stark in den Hintergrund.²⁰ Aktuelle Datenauswertungen belegen, dass eine extrem hohe klassische Keyword-Dichte oft sogar negativ mit KI-Zitationen korreliert.²⁰ Die Metrik fungiert im GEO-Score vielmehr als Warnsignal für Over-Optimization: Übersteigt die Dichte einen bestimmten Schwellenwert, beeinträchtigt dies die linguistische Natürlichkeit und damit den zuvor diskutierten Flesch-Score, was unweigerlich zu Abwertungen durch das LLM führt.

Markenerwähnungen (Brand Mentions) als primärer Autoritätstreiber

Eine inhärente methodische Limitierung reiner On-Page-Klassifikatoren (wie dem analysierten Python-Skript des RAT-Tools) besteht naturgemäß darin, dass sie externe Reputations-Signale nicht vollständig abbilden können. Die Fachliteratur und großangelegte Datenstudien aus dem Jahr 2026 zeigen jedoch unmissverständlich, dass Generative Engines primär als "Consensus Engines" fungieren.² Sie bewerten die Zuverlässigkeit einer Entität (Marke, Autor, Unternehmen) massiv danach, wie häufig und in welchem Kontext diese Entität im restlichen Internet referenziert wird. Ein umfassender GEO-Score, der in der Praxis Anwendung findet, muss zwingend diese Off-Page-Signale integrieren:

- **Unverlinkte Markenerwähnungen (Branded Web Mentions):** In der Ära des klassischen SEO waren Backlinks die dominierende Währung. Im GEO-Zeitalter verschiebt sich dies drastisch. Laut einer massiven Analyse von 75.000 Marken durch

Ahrefs (2026) korrelieren reine Markenerwähnungen – also Nennungen des Unternehmensnamens in Texten, auch ohne dass ein aktiver Hyperlink gesetzt wurde – mit einem extrem hohen Wert von 0.664 mit der Sichtbarkeit in Google AI Overviews.² Die Suchmaschine aggregiert diese Erwähnungen quer über das Web als massives Konsenssignal.² Im direkten Vergleich dazu weisen klassische, harte Backlinks lediglich eine schwache Korrelation von 0.218 auf – ein Paradigmenwechsel, der Branded Web Mentions zu einem dreimal stärkeren Signal für KI-Zitationen macht.²

- **Multimodale Autorität (YouTube):** Die Erwähnung einer Marke in Kombination mit relevanten YouTube-Videos ist der absolut stärkste externe Korrelator (0.737) für Zitationen im Google AI Mode.² Surfer-Analysen zeigen, dass YouTube-Quellen in vielen Industrien bis zu 23 Prozent der KI-Zitationen ausmachen, dicht gefolgt von Wikipedia mit 18 Prozent.²⁸ Dies unterstreicht Googles anhaltendes Bestreben, multimodale Inhalte nahtlos in KI-Antworten zu integrieren.²⁶
- **Suchvolumen der Marke (Brand Search Volume):** Das Volumen der Nutzer, die aktiv Suchanfragen nach dem spezifischen Markennamen in Kombination mit dem Thema stellen, ist ein weiterer hochgradig starker Prädiktor (Korrelation 0.392 bis 0.466) für KI-Sichtbarkeit.² Dies fungiert für die Retrieval-Engine als übergeordnetes, menschliches E-E-A-T-Signal: Nutzer, die aktiv nach einer Marke suchen, bestätigen der KI eine hohe reale Relevanz und Marktautorität.²
- **Inhaltliche Frische (Freshness):** Das Gerücht, KI-Systeme würden hyperaktuelle Inhalte pauschal um den Faktor 4.3 bevorzugen, erwies sich als nicht belegbarer Mythos.⁸ Dennoch belegt eine Analyse von knapp 17 Millionen Zitationen, dass KI-zitierte Inhalte im Durchschnitt (1.064 Tage) etwa 25,7 Prozent aktueller sind als die Resultate der klassischen organischen Top-10 (1.432 Tage).⁸ Das Vorhandensein aktueller Zeitstempel (datePublished, dateModified) in den strukturierten Daten ist somit ein positiver Faktor im GEO-Score.⁷

Synthese: Architektur eines gewichteten GEO-Score-Modells

Aus der tiefgehenden Analyse der empirischen Literatur, der konzeptionellen Variablen der Masterarbeit und der algorithmischen Dekonstruktion der Python-Klassifikatoren lässt sich final ableiten, dass ein aussagekräftiger Generative Engine Optimization (GEO) Score niemals ein eindimensionaler, starrer Wert sein kann. Um den komplexen Anforderungen der Zitationsvergabe gerecht zu werden, muss er als mehrschichtiger, gewichteter Index konstruiert werden. Dieser Index muss zwingend alle probabilistischen Phasen der von Martinez beschriebenen KI-Zitations-Pipeline (Search Activation, Crawling, Retrieval, Context Allocation, Factual Absorption, Citation) reflektieren.⁴

Die Erkenntnisse lassen sich zu folgendem Modell für einen validen GEO-Score synthetisieren:

1. **Fundamentale Barrierefreiheit (Binärer Gatekeeper):** Die grundlegende Crawlbarkeit durch dedizierte LLM-Bots (wie den GPTBot), das Fehlen von restriktiven noindex-Direktiven, eine verlässliche serverseitige Erreichbarkeit ohne Paywalls und

extrem schnelle Ladezeiten stellen im Scoring-Modell keine prozentuale Score-Erhöhung dar. Sie agieren als unabdingbares "Gate". Schlägt einer dieser Parameter fehl, muss der GEO-Score zwingend auf null gesetzt werden, da die RAG-Pipeline in Stufe 2 (Crawling) unweigerlich abbricht.⁸

2. **Strukturelle Maschinen-Kompatibilität (Gewichtung ~20%):** Positiv bewertet wird eine exzellente, fehlerfreie Ausstattung mit strukturierten Daten (JSON-LD nach Schema.org-Standards), der Einsatz semantisch logischen HTMLs (H-Tag-Kaskaden, HTML-Tabellen zur Datenpräsentation, Definitionslisten) und dedizierten FAQ-Strukturen. Diese Elemente minimieren Entitäts-Mehrdeutigkeiten massiv und erleichtern die reibungslose Extraktion durch das Retrieval-Augmented Generation System.⁶
3. **Linguistische Extrahierbarkeit und Tonalität (Gewichtung ~30%):** Eine exakt auf die Aufmerksamkeitsmechanismen von LLMs abgestimmte Textkomplexität. Optimal ist ein Flesch-Kincaid-Score zwischen 60 und 75 (entsprechend einfacher bis mittlerer Sprachkomplexität). Kombiniert mit kurzen, prägnanten Sätzen, übersichtlichen Absatzstrukturen (max. 3 Sätze) und einer direktionalen, autoritären Textstrukturierung ("Answer-First"-Prinzip) ermöglicht dies dem generativen Modell eine verlust- und halluzinationsfreie Übernahme der Aussagen in KI-generierte Passagen.⁶
4. **Evidenz, Autorität und Objektivität (Gewichtung ~30%):** Die dicht gedrängte Integration belastbarer Fakten in den Textkörper. Ein hoher Score erfordert die Messung harter statistischer Daten (Zahlen, Prozentwerte, valide Jahresangaben), den Einschluss direkter Zitate verifizierter, namentlich genannter Experten sowie eine saubere, ausgehende Verlinkungsstruktur zu Primärquellen. Diese Elemente erzeugen einen Autoritätstransfer, der das Dokument in der kompetitiven "Reranking and Context Allocation"-Phase gegenüber meinungsbasierten Texten gewinnen lässt.⁶
5. **Entitäts-Ruf und externer Konsens (Gewichtung ~20%):** Die Überprüfung der Konsistenz der Entitätsdatenbank auf der Seite (Impressum, Autoren-Schema, Unternehmensinformationen) gekoppelt mit starken Off-Page-Signalen. Hier dominieren weitreichende Markenerwähnungen in etablierten Publikationen (Branded Web Mentions) und ein signifikantes Marken-Suchvolumen, die der generativen Engine als verlässliches Konsenssignal für die Reputation und allgemeine Gültigkeit der untersuchten Quelle dienen.²

Zusammenfassend belegt die Analyse, dass Generative Engine Optimization die Grundfesten der Suchmaschinenoptimierung nicht komplett zerstört, die Prioritäten jedoch massiv und unumkehrbar verschiebt. Während traditionelles SEO jahrzehntelang primär auf Linksignale und Keyword-Platzierungen optimierte, die einen Crawler dazu bringen sollten, eine Seite als *thematisch relevant* zu erachten, optimiert GEO auf hochgradig strukturierte, linguistisch klare und faktenbasierte Signale. Diese bringen das Wahrscheinlichkeitsmodell eines Large Language Models dazu, eine extrahierte Textpassage als *wahr, präzise und risikoarm zitierbar* zu bewerten.⁴

Die in der Masterarbeits-Konzeption referenzierte RAT-Software liefert mit ihrem Python-Klassifikator ein hochgradig ausgereiftes, differenziertes und technologisch tiefgehendes Instrumentarium, um genau diesen Paradigmenwechsel empirisch skalierbar zu

erfassen.⁶ Durch die smarte Kombination von gnadenlosen technischen Checks, NLP-gestützter linguistischer Lesbarkeitsanalyse und der algorithmischen Identifikation semantischer Evidenz-Marker (Statistiken, Organisationen, Zitate) liefert das System exakt jene granularen Datenpunkte, die für die Berechnung eines wissenschaftlich fundierten, aussagekräftigen und in der Praxis hochwirksamen GEO-Scores zwingend erforderlich sind. Ein solcher Score wird in den kommenden Jahren das essenzielle Navigationsinstrument für die Sichtbarkeit im Informationsökosystem der generativen künstlichen Intelligenz darstellen.

Referenzen

1. GEO: Generative Engine Optimization - arXiv, Zugriff am Juli 28, 2026, <https://arxiv.org/pdf/2311.09735>
2. Google AI Mode SEO 2026: How to Rank in the 1B-User AI Engine - GoGoChimp, Zugriff am Juli 28, 2026, <https://www.gogochimp.com/blog/google-ai-mode-seo>
3. Generative engine optimization - Wikipedia, Zugriff am Juli 28, 2026, https://en.wikipedia.org/wiki/Generative_engine_optimization
4. A Critical Survey of Generative Engine Optimization (2023–2026) - arXiv, Zugriff am Juli 28, 2026, <https://arxiv.org/html/2607.14035v1>
5. A Critical Survey of Generative Engine Optimization (2023–2026) - arXiv, Zugriff am Juli 28, 2026, <https://arxiv.org/pdf/2607.14035>
6. kw.ini
7. How AI Search Engines Decide What to Cite (Not SEO) - AuthorityTech, Zugriff am Juli 28, 2026, <https://authoritytech.io/blog/how-ai-search-engines-decide-what-to-cite>
8. What Actually Gets You Cited in AI Search (2026 Data) - Digital Applied, Zugriff am Juli 28, 2026, <https://www.digitalapplied.com/blog/ai-search-citation-ranking-factors-2026-data-study>
9. Result Assessment Tool (RAT): empowering search engine data analysis - PMC - NIH, Zugriff am Juli 28, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12453652/>
10. 9 GEO Strategies That Increase AI Citations by 40% - xSeek, Zugriff am Juli 28, 2026, <https://www.xseek.io/blogs/articles/which-generative-engine-optimization-strategies-actually-work>
11. Google's AI SEO Guide: Focus on Helpful Content - The 215 Guys, Zugriff am Juli 28, 2026, <https://www.the215guys.com/blog/google-ai-seo-geo-guide-anti-checklist/>
12. Survey of 45 studies finds GEO rewrites can cut a page's AI retrieval 16% - PPC Land, Zugriff am Juli 28, 2026, <https://ppc.land/survey-of-45-studies-finds-geo-rewrites-can-cut-a-pages-ai-retrieval-16/>
13. GEO: GENERATIVE ENGINE OPTIMIZATION - OpenReview, Zugriff am Juli 28, 2026, <https://openreview.net/pdf?id=NV6rn7j5p5>
14. GEO: Generative Engine Optimization - arXiv, Zugriff am Juli 28, 2026, <https://arxiv.org/html/2311.09735v3>

15. A Critical Survey of Generative Engine Optimization (2023-2026) - arXiv, Zugriff am Juli 28, 2026, <https://arxiv.org/abs/2607.14035>
16. Google publishes guide to optimizing for generative AI search - Semrush, Zugriff am Juli 28, 2026, <https://www.semrush.com/blog/google-publishes-generative-ai-search-guide/>
17. Google AI Overviews GEO Statistics 2026 - Citations, CTR, and Coverage | AEO Vision, Zugriff am Juli 28, 2026, <https://aeovision.ai/articles/google-ai-overviews-geo-statistics-2026/>
18. Google AI Overviews and SEO: The 2026 Citation Guide, Zugriff am Juli 28, 2026, <https://mshahid.com/blog/google-ai-overviews-seo>
19. How to Rank in Google AI Overviews (2026): The Data-Backed, Zugriff am Juli 28, 2026, <https://www.gogochimp.com/blog/how-to-rank-in-google-ai-overviews>
20. SEO Ranking Factors 2026: 14 Critical UK SEO Factors Guide | Whitehat, Zugriff am Juli 28, 2026, <https://whitehat-seo.co.uk/blog/seo-ranking-factors>
21. Dirk Lewandowski's lab - HAW Hamburg - ResearchGate, Zugriff am Juli 28, 2026, <https://www.researchgate.net/lab/Dirk-Lewandowski-Lab>
22. Result Assessment Tool (RAT) : an open-source toolkit for conducting studies based on search results - REPOSIT HAW Hamburg, Zugriff am Juli 28, 2026, <https://reposit.haw-hamburg.de/handle/20.500.12738/19145>
23. Webinar: Result Assessment Tool (RAT): An Open-Source Toolkit for Conducting Studies based on Search Results, Zugriff am Juli 28, 2026, <https://www.asist.org/meetings-events/webinars/result-assessment-tool/>
24. Optimizing your website for generative AI features on Google Search, Zugriff am Juli 28, 2026, <https://developers.google.com/search/docs/fundamentals/ai-optimization-guide>
25. The Complete Guide to Generative Engine Optimization (GEO) | by joachim | Medium, Zugriff am Juli 28, 2026, https://medium.com/@joachim_43659/the-complete-guide-to-generative-engine-optimization-geo-39fbd8f02f03
26. Zugriff am Juli 28, 2026, <https://mikekhorev.com/google-ai-overview>
27. Readability Levels That Win GEO / AEO Citations - rocketblue Articles, Zugriff am Juli 28, 2026, <https://rocketblue.ai/articles/readability-levels-that-win-geo-aeo-citations/>
28. Google Preferred Sources & AI Overviews: Enhance Visibility - Elementera, Zugriff am Juli 28, 2026, <https://www.elementera.com/blog/google-preferred-sources-aeo-ai-search-overview>
29. AI Overviews optimization guide: Ranking in Google AI Overviews - Search Engine Land, Zugriff am Juli 28, 2026, <https://searchengineland.com/guide/how-to-optimize-for-ai-overviews>